انواع طبقه بندی ها

پروژه ششم

علی رضاقلی زاده 610389126

چکیده

یکی از مراحل پردازش و تشخیص یک تصویر بعد از بدست آوردن بردار ویژگی ، طراحی یک طبقه بند است تا بتواند یک سیگنال را بدرستی تشخیص دهد . البته طبقه بند مشخصی وجود ندارد که بتوان با قطعیت یک سیگنال را طبقه بندی کرد حتی طبقه بندی نیز موجود نیست که برای همه مسایل دارای بازدهی معین باشد و به همین دلایل باید برای هر مسأله دنبال طبقه بند یا طبقه بند های مطلوب آن مسأله بود .

پس از به دست آوردن بردارهای ویژگی نوبت به طبقه‌بندی داده‌ها می رسد. به طور کلی انواع طبقه‌بندی کننده‌ها در ابتدا بر روی گروهی از بردارهای ویژگی تحت عنوان داده‌های یادگیری، آموزش می‌بینند و پس از تنظیم پارامترهای مربوط به آن‌ها، مرحله ارزیابی آغاز می‌گردد. در این مرحله عملکرد طبقه‌بندی‌کننده با طبقه‌بندی گروهی از بردارهای ویژگی که پیش از این در آموزش شرکت نکرده‌اند، مورد ارزیابی قرار می‌گیرد. در ادامه به بررسی 4 مورد از طبقه‌بندی‌کننده‌ها روی داده های مختلف نظیر حلزونی ، فنوم و ست ایمیج می‌پردازیم. این طبقه‌بندی‌کننده‌ها عبارتند از طبقه‌بندی‌کننده نزدیکترین و چندمین نزدیک ترین همسایگی، طبقه‌بندی‌کننده بیز و طبقه‌بندی‌کننده پارزن .

کلمات کلیدی: طبقه بند ، داده آموزش ، داده تست

مقدمه

به طور کلی روش‌های گوناگونی برای طبقه‌بندی اطلاعات وجود دارد که از نظر سرعت انجام طبقه‌بندی و نحوه آن با یکدیگر متفاوت می‌باشند. طبقه‌بندی‌کننده‌ها به دو دسته باسرپرست[1] و بدون سرپرست[2] تقسیم می‌شوند. طبقه‌بندی‌کننده‌های باسرپرست نیازمند بخشی از داده‌ها که کلاس آنها مشخص شده است (داده‌های آموزشی[3]) می‌باشند تا با کمک آنها بقیه داده‌ها را طبقه‌بندی و برچسب‌گذاری نمایند، ولی روش‌های بدون سرپرست تعداد ورودی‌های کمتری لازم دارند و تنها داده‌هایی که می‌بایست طبقه-بندی شوند را به عنوان ورودی دریافت می‌کنند. که ما در این گزارش طبقه بند های با سرپرست نظیر نزدیک ترین همسایه ، چندمین همسایه ، بیز و پارزن را مورد بررسی قرار داده و پیاده سازی می کنیم .

طبقه بندی با سرپرست به سه دسته تقسیم می شوند : دسته اول طبقه بندی ها ، بر اساس شباهت [4] ؛ دسته دوم بر اساس روش های آماری[5] و دسته سوم بر اساس روش شبکه های عصبی[6] است . نزدیک ترین و چندمین نزدیک ترین همسایه در دسته اول و بیز و پارزن جزء دسته دوم قرار می گیرند .

---

[1] Supervised Classifier
[2] Unsupervised Classifier
[3] Train Data
[4] Consept of similarity
[5] Probabilistic approach
[6] Neural Networks

نشان خواهیم داد که از لحاظ سرعت طبقه بندی ، نزدیک ترین و چندمین نزدیک ترین همسایه عملکرد بسیار ضعیف تری دارند .

داده حلزونی :

500 داده از هر کلاس انتخاب می کنیم که 200 داده از آن را برای آموزش و 300 داده را برای تست بر می داریم (از هر کلاس).

قابل ذکر است که کلاس داده های تستمان را داریم ولی طبقه بند ها این را نمی دانند و در آخر که روی آنها طبقه بند را زدیم برای بدست آوردن بازدهی آن طبقه بند مورد استفاده قرار می گیرد .

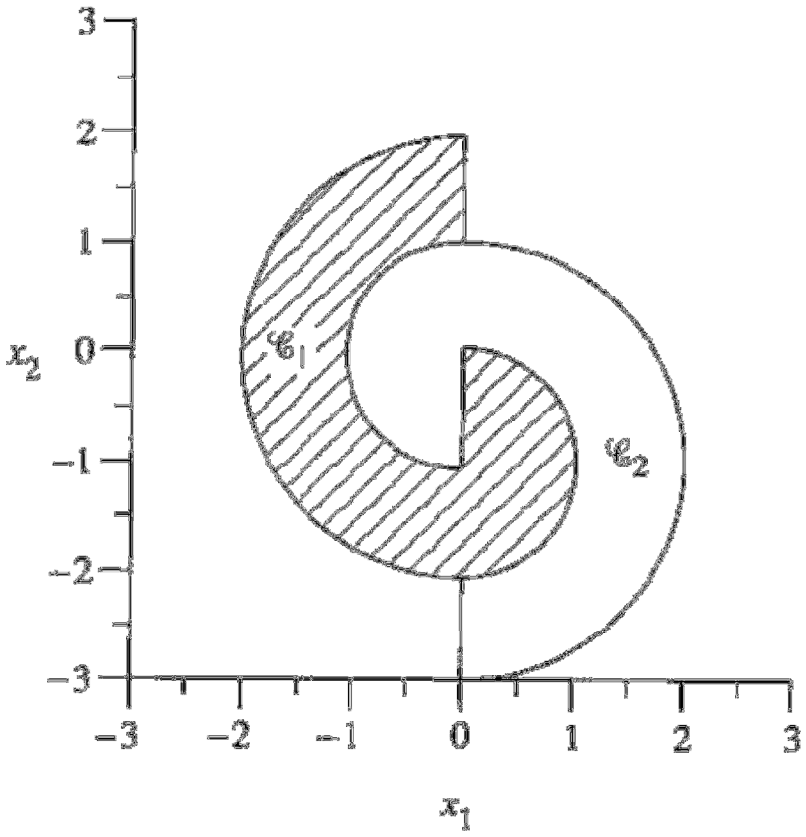

شکل 1 قسمت هاشور خورده کلاس 1 است .

انواع طبقه بند ها روی داده ها و مقایسه آنها

1. نزدیک ترین و K امین نزدیک ترین همسایه

روش KNN قادر است از میان داده‌های گوناگون که هر یک با یک مجموعه از بردارهای ویژگی مشخص می‌گردند، K داده که به داده مورد بررسی نزدیکترند را انتخاب کرده و سپس با توجه به کلاس در برگیرنده اکثریت داده‌های انتخاب شده، تصمیم نهایی برای طبقه‌بندی بردار مورد بررسی را اتخاذ نماید. مقدار K در این روش همواره عددی انتخاب می شود که منجر به بهترین نتیجه طبقه‌بندی برای داده‌های آموزش می‌گردد و سپس این مقدار برای طبقه‌بندی داده‌های آزمایش نیز مورد استفاده قرار می‌گیرد. معیاری که برای سنجش فاصله بین دو بردار در این پایان‌نامه به کار گرفته شده است، فاصله اقلیدسی می‌باشد.

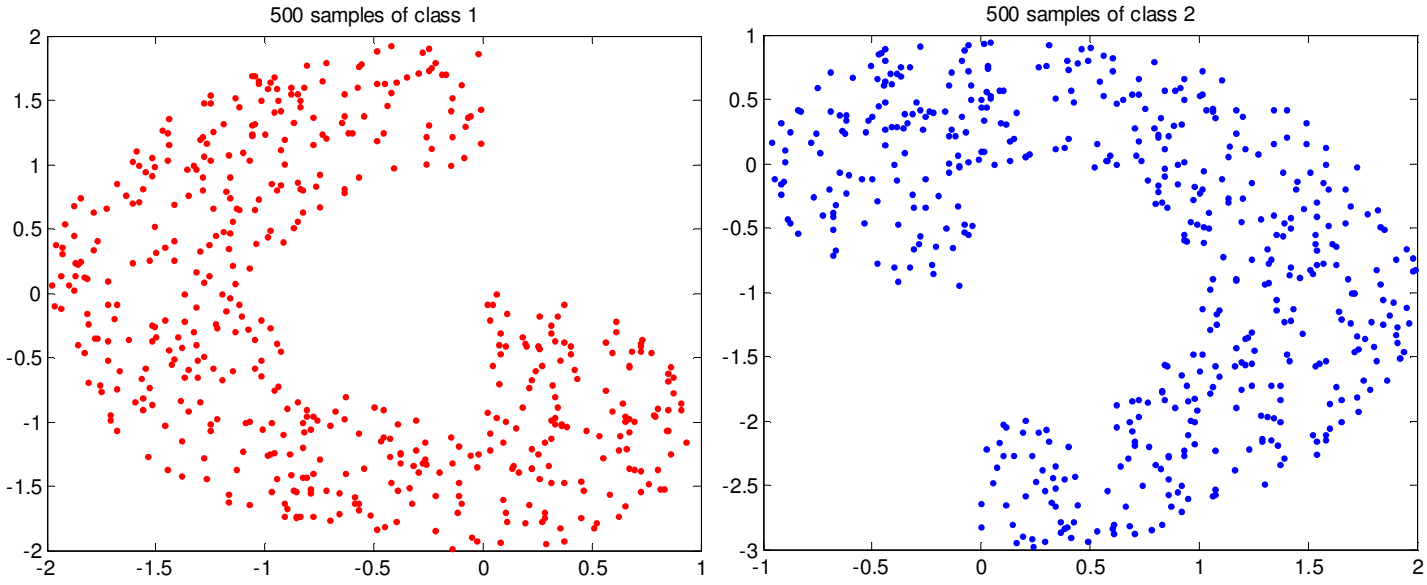

a b

شکل 2 (a) و(b) به ترتیب 500 داده انتخابی از کلاس 1 و2 است .

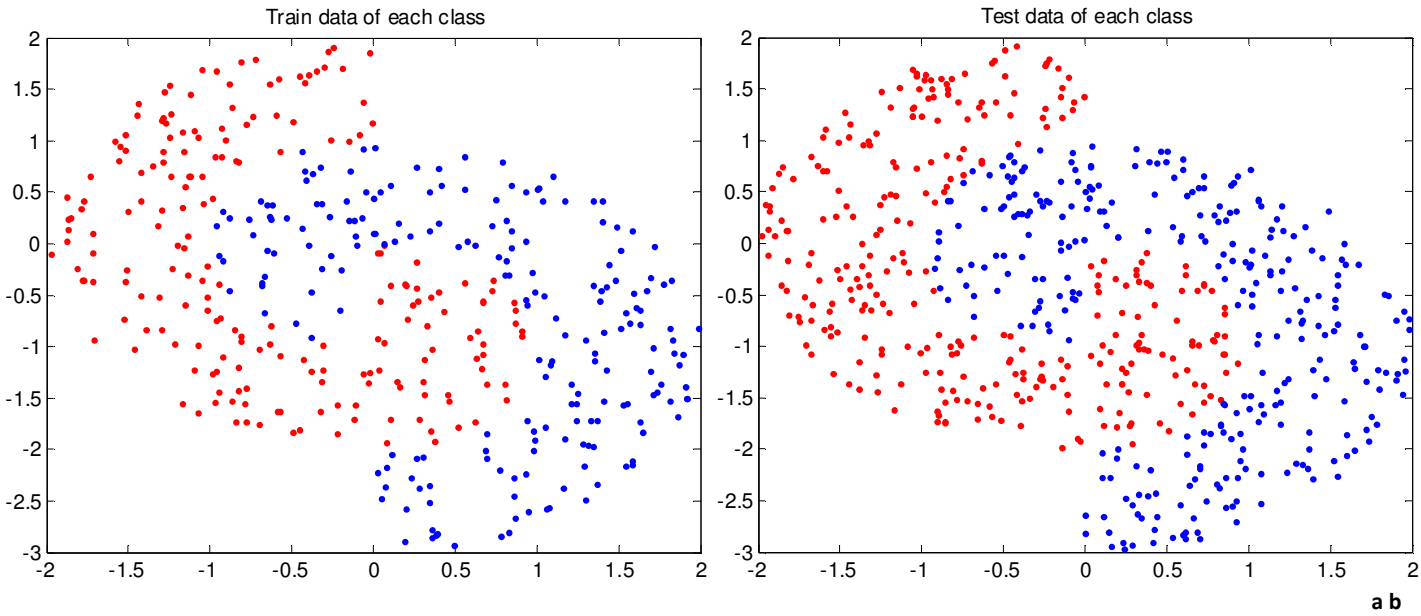

شکل 3 (a) داده آموزش و (b) داده تست

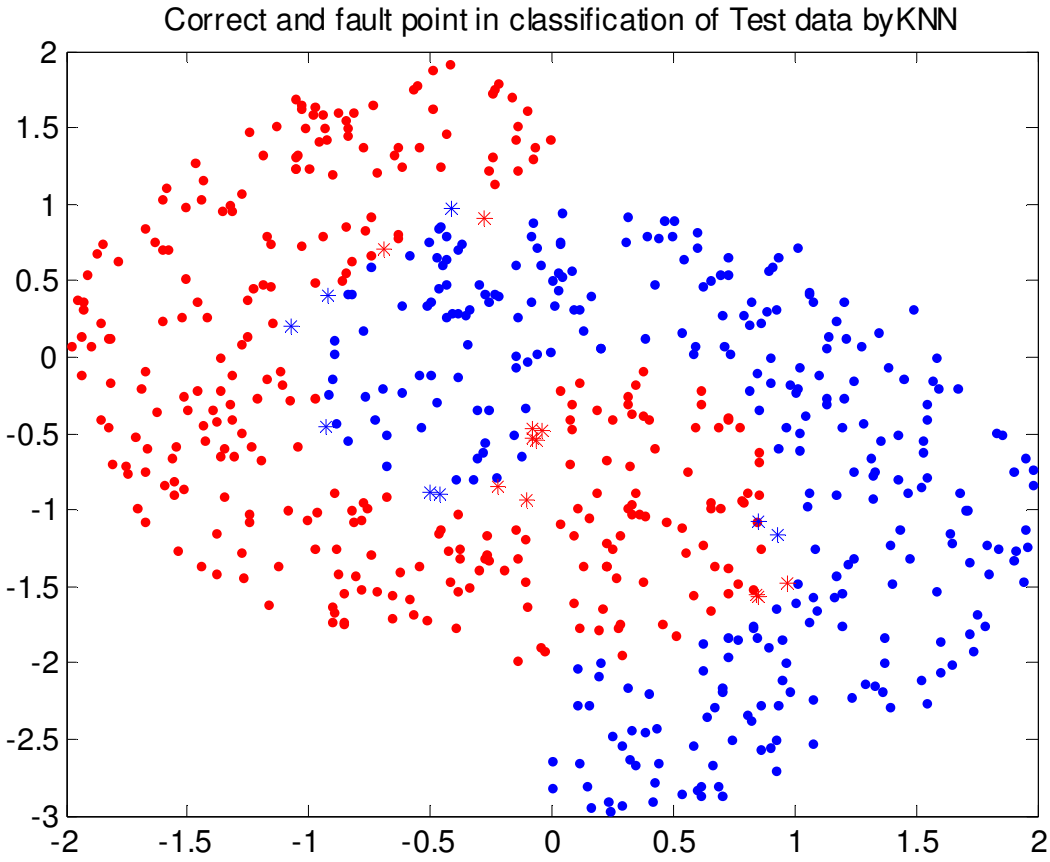

شکل 4 داده های تست هستند که با طبقه بند K امین نزدیک ترین همسایه (K=1) طبقه بندی شده اند .از 600 داده تست ، 581 داده به درستی و 19 داده به اشتباه طبقه بندی شده اند (بازدهی 96.83 درصدی)؛ نقطه ها معرف دادهایی اند که به طور صحیح طبقه بندی شده اند وستاره معرف طبقه بندی اشتباه داده ها است .

همان طور که دیده می شود در این روش (اولین نزدیک ترین همسایه) احتمال خطا در داده های روی مرز خیلی بیشتر است حتی می توان گفت که در این روش تنها داده های نزدیک مرز ممکن است به اشتباه طبقه بندی شوند .

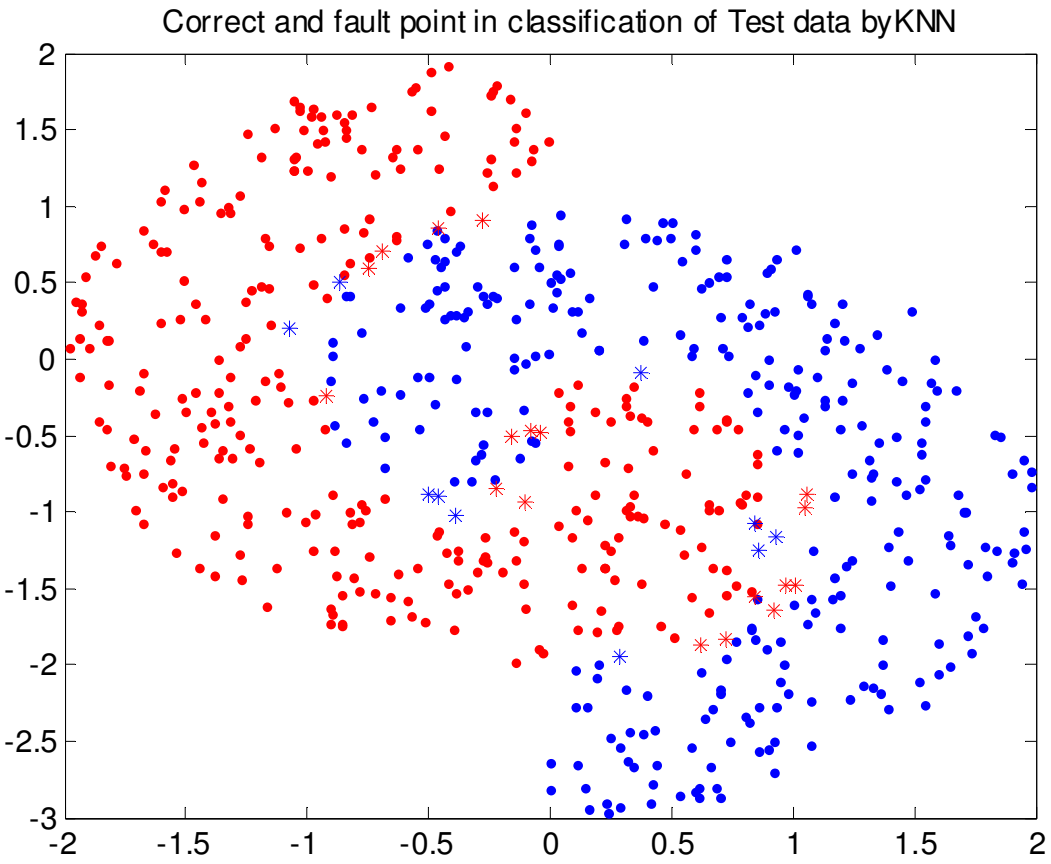

شکل 5 طبقه بندی داده ی شکل 3 (a) با طبقه بند K (K=2) امین نزدیک ترین همسایه ؛ در این طبقه بند از 600 داده ی تست ، 572 داده به درستی طبقه بندی شده اند و 28 داده به نادرستی (بازدهی 95.33 درصدی) که داده های درست در شکل با نقطه و داده های اشتباه طبقه بندی شده با ستاره نشان داده شده است .

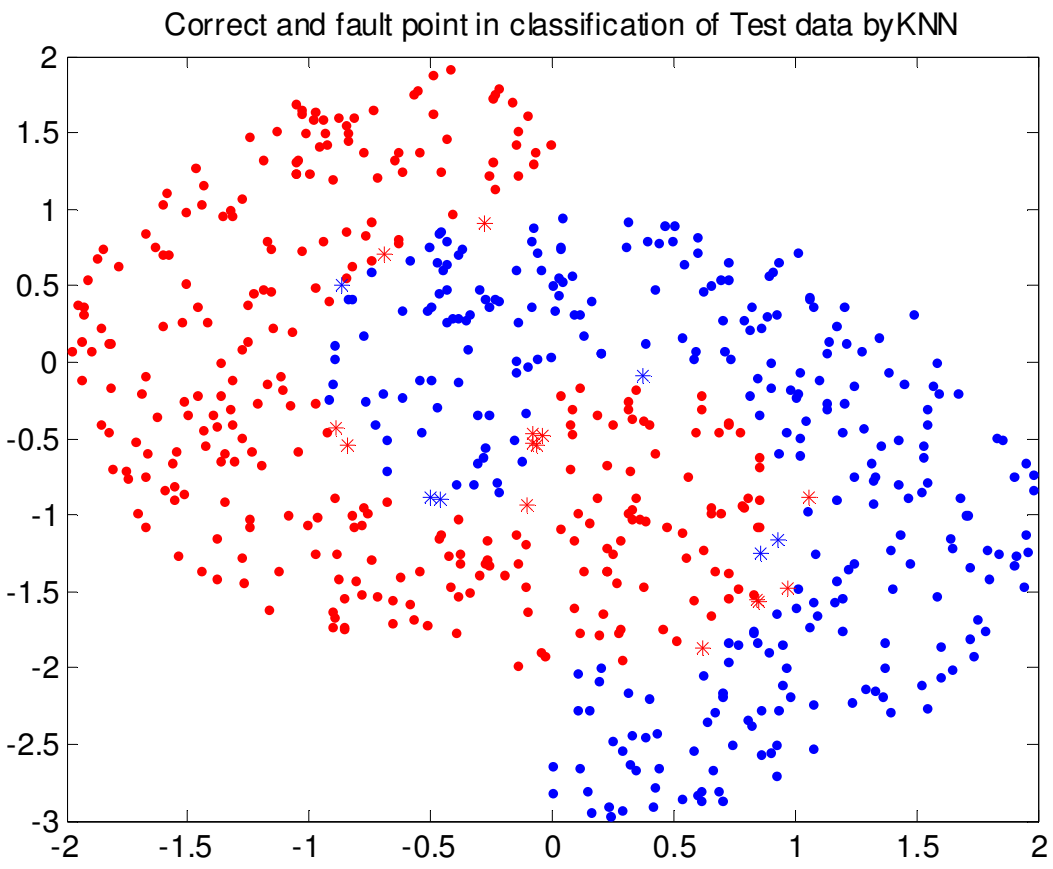

شکل 6 طبقه بندی داده ی شکل 3 (a) با طبقه بند K (K=3) امین نزدیک ترین همسایه ؛ در این طبقه بند از 600 داده ی تست ، 680 داده به درستی طبقه بندی شده اند و 20 داده به نادرستی (بازدهی 96.67 درصدی) که داده های درست در شکل با نقطه و داده های اشتباه طبقه بندی شده با ستاره نشان داده شده است .

K	1	2	3	4	5	6	7	8	9
Performance	96.83	95.33	96.67	95.83	96.50	95.50	96.00	96.00	96.33

K	10	11	12	13	14	15	16	17	18
Performance	96.17	96.67	96.00	95.83	95.50	94.83	95.33	94.83	95.50

جدول 1 بازدهی k امین نزدیک ترین همسایگی با تغییر k

که بین k های 1 تا 400 بررسی شده بازدهی k=1 بالا ترین محاسبه شده است .

پس می توان نتیجه گرفت که در طبقه بند k امین همسایه ی نزدیک احتمال خطا در داده های مرزی از بقیه داده ها بیشتر است همچنین سرعت محاسبه ی این طبقه بند به دلیل نیاز به داشتن فاصله از تمام داده های آموزش برای هر داده تست ، بسیار پایین ارزیابی می شود .

2. طبقه بند بیز

این طبقه بند بر اساس تحلیل آماری روی داده های آموزش در هر کلاس برای هر داده جدید (داده ی تست) قضاوت می کند بدین گونه که احتمال تعلق داده ی جدیدنسبت به همه ی کلاس ها را بدست می آورد سپس این مقدار برای هر کلاس که بیشتر بود داده جدید را به آن کلاس برچسب گذاری می کنیم .

$$P(w_i \mid x) = \frac{p(x \mid w_i)P(w_i)}{p(x)} \qquad (2\text{-}1)$$

$P(w_i \mid x)$:احتمال تعلق داده x به کلاس w_i است .

$p(x \mid w_i)$: احتمال داده x در کلاس w_i است .

$P(w_i)$: احتمال انتخاب کلاس w_i از میان بقیه ی کلاس ها .

$p(x)$: احتمال قرار گرفتن x در دامنه ی (فضای) کلاس ها .

که برای بدست آوردن $p(x \mid w_i)$ لازم است که تابع توزیع آن را داشته باشیم که این مستلزم آن است که ما کل فضای کلاس را داشته باشیم در حالی که ما جز تعدادی داده ی آموزش چیز دیگری از آن کلاس نداریم . برای این مشکل ، می آیند تابع توزیع را تخمین می زنند که ما در اینجا با تابع گوسی این کار را انجام می دهیم .

در شکل 7 نیز نمونه ای از یک تابع گوسی در دو بعد با میانگین (0, 0) را نشان می دهد .

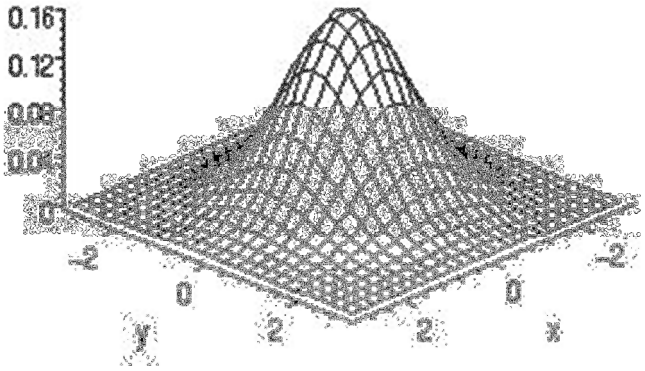

شکل 7 یک تابع گوسی در دو بعد را نشان می دهد .

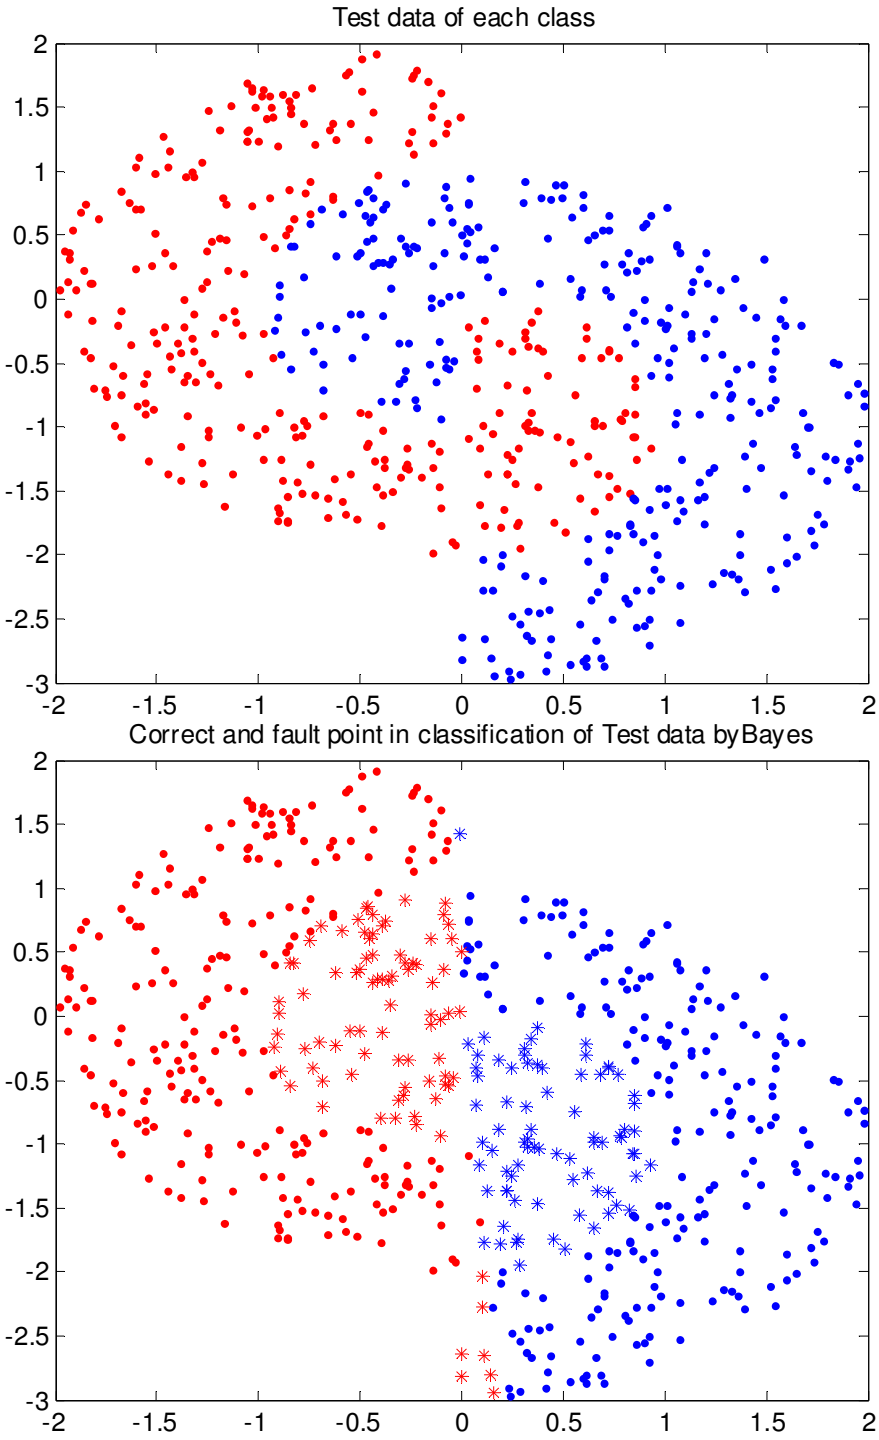

شکل 8 (b) بعد از اعمال طبقه بندی بیس روی داده تست (a) است . داده های غلط طبقه بندی شده در (b) با ستاره (163 داده) و داده های صحیح (437 داده) با نقطه نشان داده شده اند .

	Class 1	class 2
Fiture 1	-0.6103	0.6817
fiture 2	-0.2018	-0.7632

جدول 2 میانگین هر کلاس (داده های ما در حلزونی دو بعدی اند پس دارای دو ویژگی اند) .

در این روش طبقه بندی داده هایی به طور اشتباه مورد قضاوت قرار می گیرند که داخل ناحیه ی تداخل تابع های توزیع تخمین زده از هر کلاس باشد یعنی مطابق شکل 9 داده ی مورد نظر در داخل بازه ی حدودا صفر تا چهار قرار گیرد در این صورت احتمال خطا تشخیص دادن توسط طبقه بند وجود دارد ؛ در مثال شکل 9 اگر داده ای که در واقع عضو کلاس 1 است در ناحیه ی دو تا چهار یا داده ای که در واقع عضو کلاس 2 است در ناحیه ی صفر تا دو قرار گیرد درآن صورت این داده ها به اشتباه به کلاس دیگری طبقه بندی می شود .

طبقه بند بیز روی این داده بازدهی 72.83 درصدی را داراست

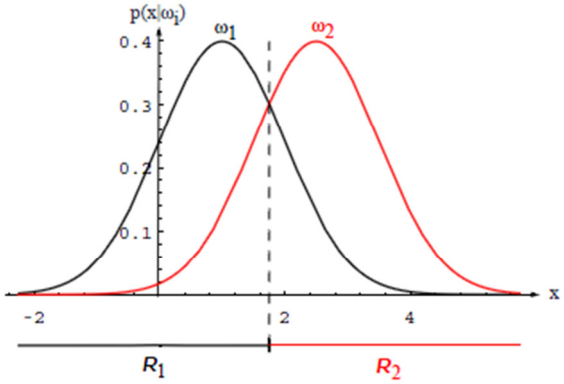

شکل 9 دو تابع گوسی به عنوان تخمینی برای تابع توزیع دو کلاس w1 و w2

3. طبقه بند پارزن

روش پارزن روشی ناپارامتری برای تخمین تابع چگالی احتمال است. در این روش که با تعمیم روش هیستوگرام بدست آمده است، به صورت محلی تابع چگالی احتمال را تقریب میزنیم. اساس کار این روش مشابه هیستوگرام است با این تفاوت که ما در این روش خود را مستقیما با داده های با ابعاد بالا درگیر می کنیم. روش کار به صورت زیر است:

گام اول- یک ابر مکعب با طول ضلع h را در نظر بگیرید. حجم این مکعب برابر با $v = h^n$ که n بعد فضای داده ها (در این مساله برابر با 2) است.

گام دوم- برای هر نقطه x در تخمین pdf، مرکز این مکعب را بر روی داده مورد نظر قرار می دهیم.

گام سوم- تعداد نمونه های واقع شده در این مکعب را می شمریم. چنانچه این تعداد برابر با K باشد، تخمین ما به صورت زیر در می آید:

$$f(x) = \frac{K}{vN} = \frac{1}{h^n N} \sum_{q=1}^{N} \phi\left(\frac{x - x_q}{h}\right)$$

$$\phi(u) = \begin{cases} 1 & |u| < 0.5 \\ 0 & o.w. \end{cases}$$

که در آن N تعداد نمونه ها است. تابع $\phi(u)$ می تواند مثلثی، گوسی و یا هر تابع دلخواه دیگر باشد، مشروط بر آنکه مساحت زیر آن برابر با یک باشد.

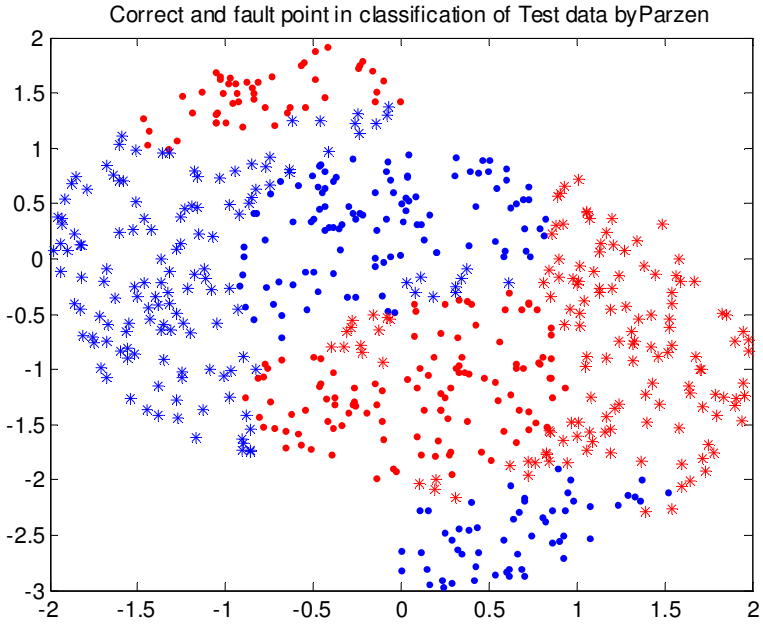

a

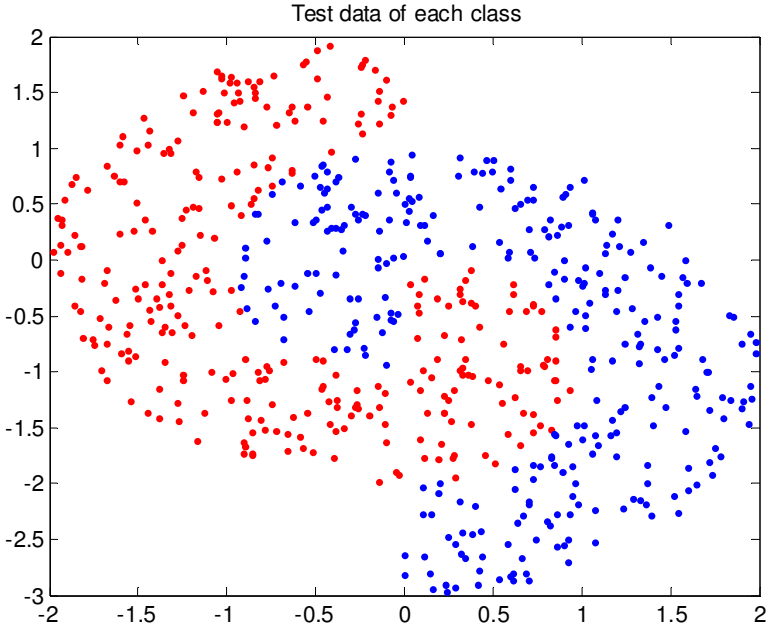

b

شکل 10 (b) بعد از اعمال طبقه بندی پارزن روی داده تست (a) است . داده های غلط طبقه بندی شده در (b) با ستاره (277 داده) و داده های صحیح (323 داده) با نقطه نشان داده شده اند

Code 1: K _Nearest neighbor

```
function
ClassifiedSet=K_NearestN(TrainSet,TestSet,K,NumberOfClass)
%TrainSet is Train point in each class (each point is in row)
%TestSet is n*2 matrix that you must never confident on second
column
%(first column is point(in each dimention)).
K_SelectedPointSet=[];          %is k*2 matrix that store point
in first column and Label in second.
% DistanceFromK_Selected=[];    %respectivly to K_NearestPointSet
/ is k*1 matrix
 ClassifiedSet=[];
% LocalD=0;
% %LocalD is Max Distance of point from K selected as nearest
point of Training Set
% pivot=[TestSet(1,1:end-1)];
% %pivot is one of the Test point . we want just find distance
this piont
% %from other Training Set ,and use these to finde distance for
other Test
% %points. BUT AT LAST WE DONT USE THIS THINKING BECOUSE OF MORE
TIME
% %NESESSERY TO COMPUTE.
% DistanceFromPivot=[];   %is (number of TrainSet)*3 that store
distance of
% %correspond point(that store in first column)from Pivot in
third column
% %and second column is label of correspond point in column 1.
% d=1;
       %---------------Find K nearest point from PIVOT----------
----
%     for i=1:size(TrainSet,1)
%             d=sqrt(sum((pivot(1,:)-TrainSet(i,1:end-1)).^2));
%             if LocalD > d
%                 replaceNum=max(DistanceFromK_Selected);
%                 b=(DistanceFromK_Selected == replaceNum);
%                 DistanceFromK_Selected(b)=d;
%                 index=transpose([1:K]);
%                 ind=index(b);
%                 K_SelectedPointSet(ind(1,1),:)=TrainSet(i,:);
%
%                 LocalD=max(DistanceFromK_Selected);
%
```

```
%             end
%             if i <= K
%
DistanceFromK_Selected=[DistanceFromK_Selected;d];
%
K_SelectedPointSet=[K_SelectedPointSet;TrainSet(i,:)];
%                 if i==K
%                     LocalD=max(DistanceFromK_Selected);
%                 end
%             end
%             DistanceFromPivot=[DistanceFromPivot;TrainSet(i,:)
d];
%     end
%
ClassifiedSet=LabelUnKnownPoint(pivot,K_SelectedPointSet,Classif
iedSet,NumberOfClass);
    DistanceFromThis=[];    %Distance of other Traning point
From current
    %Test point. DistanceFromThis is n*3 that first column place
Train point
    %label and distance also place in second and third
respectively
    for j=1:size(TestSet,1)
        point(1,:)=TestSet(j,1:end-1);
        %---------------Find K nearest point-------------
        for i=1:size(TrainSet,1)
            d=sqrt(sum((point(1,:)-TrainSet(i,1:end-1)).^2));
            DistanceFromThis=[DistanceFromThis;TrainSet(i,1:end)
d];
        end
        dis=DistanceFromThis(:,end);
        [B,IX]=sort(dis,1);

SortedDFT=zeros(size(DistanceFromThis,1),size(DistanceFromThis,2
));
        for l=1:size(DistanceFromThis,1)
            SortedDFT(l,:)=DistanceFromThis(IX(l),:);
        end
        SortedDFT;
        for h=1:K

K_SelectedPointSet=[K_SelectedPointSet;SortedDFT(h,1:end-1)];
        end
        %K_SelectedPointSet

ClassifiedSet=LabelUnKnownPoint(point,K_SelectedPointSet,Classif
iedSet,NumberOfClass);
```

```
        %this function do labeling by means of K selected
point's label
        DistanceFromThis=[];
        K_SelectedPointSet=[];
    end
end

function
ClassifiedSet=LabelUnKnownPoint(point,K_SelectedPointSet,Classif
iedSetIn,NumberOfClass)
    %K_SelectedPointSet is k*2 matrix that store point in first
column and
    %Label in second.
    %with assumption that label of each class are from 1 to
NumberOfClass
    %(Note in 1).
    LabelArray=K_SelectedPointSet(:,end);
    NumberInEachClass=zeros(NumberOfClass,1);   %is column
matrix that stor
    %number of piont in each class(WhatPoint is in
K_SelectedPointSet).
    for i=1:NumberOfClass
         NumberInEachClass(i,1)=sum(LabelArray==i);
    end
    ClassLabel=LaUnPoByK_NNStrategy(NumberInEachClass);
    ClassifiedSetIn=[ClassifiedSetIn;point ClassLabel];
    ClassifiedSet=ClassifiedSetIn;

end

function ClassLabel=LaUnPoByK_NNStrategy(NumberInEachClass)
%NumberInEachClass is single column that show number of point in
%each(1,2,..)class(correspond to its index).
%class
index=transpose([1:size(NumberInEachClass,1)]);
    CL=index(NumberInEachClass==max(NumberInEachClass));
    ClassLabel=CL(randi([1:size(CL,1)],1),1);
end
```

Code 2: Bayes

```
function
ClassifiedSet=ClassifyByBayes(TrainSet,TestSet,NumberOfClass)
    %-----------separate each class of Training Set-----------
    Classes=cell(1,NumberOfClass);
```

```
    for i=1:NumberOfClass
      Classes{1,i}=cell(4,1);%Store Training point in each class
     %correspond to its column index(for instance i's class
store in
     %classes{1,i}{1,1})and Mean of ech class(store in
Classes{1,i}{2,1})and
     %variance is stored in Classes{1,i}{3,1}.Each of these(mean
and
     %variance are column matrix.
    end
    for i=1:NumberOfClass
        LCurrclass=(TrainSet(:,end)==i);      %label of current
class
        Currclass=TrainSet(LCurrclass,1:end-1);        %with out
label

        Classes{1,i}{1,1}=Currclass(:,1:end);    %stor with out
label
        %a=Classes{1,i}{1,1}
    end
    %-----------Find mean of each class-----------------------
    Sum=0;
    for i=1:NumberOfClass
        Points=Classes{1,i}{1,1};   %each point is in row
        Sum=sum(Points);                    %execute sum of each
dimention
        Mean=Sum./(size(Points,1))        %execute Mean of each
dimention
        %Mean is (dimention of point)*1.
        Classes{1,i}{2,1}=Mean;

        MeanSet=[];        %at last became same size of Points
matrix to excecute legaly
        for j=1:size(Points,1)
            MeanSet=[MeanSet;Mean];
        end
        Variance =sum((Points-MeanSet).^2);
        Variance=(Variance./size(Points,1));

        SD=Variance.^0.5;   % SD is row matrix
        Classes{1,i}{4,1}=SD;
        Sum=0;
    end

    for i=1:NumberOfClass
        Points=Classes{1,i}{1,1};
```

```
        Cov=Covariancefunc(Points);     %Covariancefunc:calculate
covariance
        %therough   each   column   (dimention   is   number   of
column);Cov is
        %(dim*dim) matrix.
        Classes{1,i}{3,1}=Cov;

    end
    %---------------------- classifying Test points-------------
    index=[1:NumberOfClass];
    ClassifiedSet=[];
    for i=1:size(TestSet,1)
        currPoint=transpose(TestSet(i,1:end-1));   %currPoint   is
column matrix
        Posterior=zeros(1,NumberOfClass);    %THIS IS ROW MATRIX
THAT SRORES posterior of each class
        for j=1:NumberOfClass
            Cov=Classes{1,j}{3,1};
            po=Classes{1,j}{1,1};
            d=size(po,2);
            m=transpose(Classes{1,j}{2,1});     %naw SD is column
matrix
            Pi=1/(NumberOfClass); %Pi is prior for i-th class
            P=-(d/2)*log(2*pi)-0.5*log(det(Cov))-
0.5*(transpose(currPoint-m))*(inv(Cov)*(currPoint-m))+log(Pi);
            Posterior(1,j)=P;
        end
        c=index(Posterior == max(Posterior));
        ClassifiedSet=[ClassifiedSet;transpose(currPoint) c];
    end

end
```

Code 3: Parzen

```
function Classified=Parzen(TrainSet,TestSet,r,NumberOfClass)
    ClassifiedSet=[];
    for i=1:size(TestSet,1)
        Point=TestSet(i,1:end-1);
        NearestSet=[];
        for j=1:size(TrainSet,1)
            TrainPoint=TrainSet(j,1:end-1);
            dis=sqrt(sum((Point-TrainPoint).^2));
```

```
            if dis <= r
                NearestSet=[NearestSet;TrainPoint
TrainSet(j,end)];
            end
        end

ClassifiedSet=ParzenDecision(NearestSet,ClassifiedSet,Point,Numb
erOfClass);
    end
    Classified=ClassifiedSet;

end
function
Classified=ParzenDecision(NearestSet,ClassifiedIn,Point,NumberOf
Class)
    %in this function we use Parzen method (we construct normal
destribute
    %for each point of one class and then we sum them.
    %NearestSet consist of real label of each point at end
column .
    label=NearestSet(:,end);
    Px=zeros(1,NumberOfClass);
    for i=1:NumberOfClass
        ThisClass=(label==i);
        Class=NearestSet(ThisClass,1:end-1);  % find each point
of i's class.
        %points in Class is with out label
        Px(1,i)=Priority(Class,Point,NumberOfClass);

    end
      m=Px(1,1);
        index=[];
        for h=1:NumberOfClass
            if Px(1,h) > m
                ind=h;
                index=[];
                index=[ind];
                m=Px(1,h);

            end
            if Px(1,h) == m
                index=[index;h];
            end
        end
        if size(index,1)==1
            y=1;
        else
```

```
            y=randi([1,size(index,1)],1);
        end
        c=index(y,1);
        ClassifiedIn=[ClassifiedIn;Point c];
    Classified=ClassifiedIn;
end

function g=Priority(Class,Point,NumberOfClass)
%assume gousian function for each point in class and gain
probablity of
%being 'Point' in this class
g=0;
Point=transpose(Point);
    for i=1:size(Class,1)
        Xi=Class(i,:);
        m=transpose(Xi);
        Cov=0.05.*[0.5 0;0 0.5];
        d=size(Xi,2);
        Pi=1/(NumberOfClass);
        g=g+(-(d/2)*log(2*pi)-0.5*log(det(Cov))-
0.5*(transpose(Point-m))*(inv(Cov)*(Point-m))+log(Pi));
    end

end
```

References

[1] RO **Duda**, PE **Hart**, and DG Stork, **Pattern Classification**, New York